UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Industrial

PROYECTO INTEGRADOR: REGRESIÓN

CASO 1

Pronóstico semanal de ventas por tienda

Integrantes del equipo

Jeremías Martín Cisternas Campos
Andrés Ignacio Alan Pino Montecino
Matías Alejandro Jara Pérez
Pablo Eduardo Bustos Loyola
Gabriel Eduardo Moreira Hidalgo

PROFESOR: Luis Rojo-González, Ph.D.

ASIGNATURA: Estadística Aplicada

SANTIAGO – CHILE
2026

Resumen ejecutivo

El Random Forest fue seleccionado por RMSE mínimo en la ventana cronológica de selección. En validación obtuvo 73.2 mil frente a 101.1 mil del baseline; en el test final, 57.9 mil frente a 74.5 mil (22.3% menos RMSE). La cobertura observada de los intervalos nominales del 95% fue 96.9% en test.

1. Problema, datos y disponibilidad temporal

La predicción puede apoyar la planificación semanal de demanda. Cada fila del modelo representa una tienda en una semana; la respuesta continua es la suma de *Weekly_Sales* de sus departamentos. Se predice la semana t con datos observados hasta t-1 y se actualiza al observar cada semana. El resultado no estima utilidad, quiebres de stock ni ventas por departamento.

Elemento	Definición y alcance
Datos	Kaggle Walmart Recruiting: 421.570 filas tienda-departamento; 45 tiendas, 81 departamentos y 143 semanas. Período 05 feb 2010-26 oct 2012.
Panel modelable	Agregación a 6.435 filas tienda-semana; 4.095 quedan tras exigir las 52 semanas de historia del rezago anual.
Decisión y horizonte	Planificación semanal de demanda; horizonte de una semana, con rezagos observados hasta t-1.
Fuente y licencia	Descarga de Kaggle. La página de datos indica “Subject to Competition Rules”; no se presenta como licencia abierta.
Alcance	La competencia original predice tienda-departamento con WMAE. Este estudio agrega por tienda-semana y evalúa con RMSE/MAE/R^2.

Calidad de datos y corte de predicción

Hallazgo	Tratamiento / cifra
Faltantes externos	MarkDown1-5: 50.5% a 64.3% por variable; se usan rezagados y banderas de ausencia. La imputación por mediana se ajusta dentro del entrenamiento de cada fold.
Otras columnas	CPI y Unemployment tienen 7,1% de faltantes y se excluyen porque el momento de publicación no queda acreditado. Fecha, tienda e IsHoliday son conocidas al emitir el pronóstico.
Auditoría	1.285 ventas negativas (0,305%) y 73 en cero conservadas; cero duplicados de clave en las comprobaciones del script.

Las variables de ventas usan rezagos 1, 4 y 52 semanas y promedios móviles de 4 y 13 semanas. Temperature, Fuel_Price y MarkDown1-5 se incorporan rezagadas una semana; los valores faltantes se imputan dentro de cada ajuste.

Relaciones e inferencia

2. Relaciones e inferencia

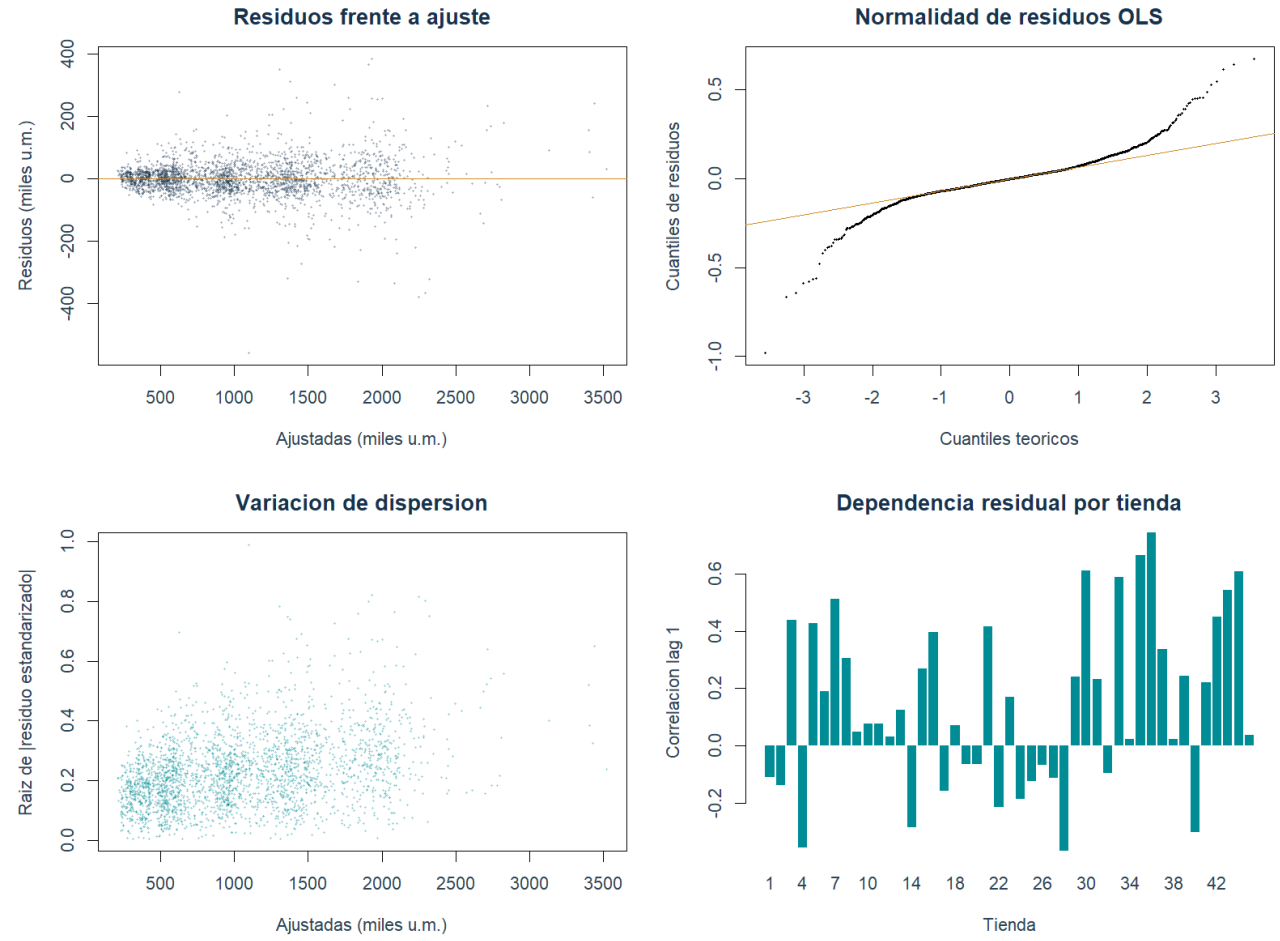
Se ajustó un OLS de referencia en el bloque de desarrollo, antes de seleccionar el sistema final. El coeficiente de *sales_lag52* mide la asociación parcial entre ventas de la misma semana del año anterior y venta semanal actual, manteniendo constantes los otros predictores. El ajuste usa 2.655 tienda-semanas, 45 tiendas y 59 semanas.

Parametro	Pendiente original	IC 95%	Cambio por 100.000 previos	IC 95% del cambio
sales_lag52	0.7675	[0.6886; 0.8463]	76,746 u.m.	[68,862; 84,630] u.m.

Una diferencia de 100.000 unidades monetarias en ventas de la misma semana del año anterior se asocia con 76,746 unidades más de venta semanal esperada (IC 95%: 68,862 a 84,630; p < 0,001). La magnitud es comparable al RMSE global del test (57.9 mil), aunque su utilidad económica depende de costos y márgenes que no están en los datos. Es una asociación predictiva, no un efecto causal.

Diagnósticos OLS

Diagnóstico	Resultado	Lectura
Multicolinealidad	VIF máximo 214.7 en sales_roll4; condición 96.9.	Los rezagos y promedios de ventas se solapan; interpretar coeficientes con cautela.
Dependencia residual	Correlación lag-1 mediana 0.078; máximo por tienda 0,742.	Hay heterogeneidad temporal entre tiendas; la inferencia agrupa por tienda y semana.
Covarianza robusta	Se recortaron 41 autovalores negativos para proyectar la covarianza a semidefinida positiva.	El IC y el p-valor del OLS son evidencia de referencia; conviene leerlos conservadoramente.



Graficos de residuos frente a ajuste, cuantiles, dispersion y correlacion residual por tienda.

Validación y preparación

3. Validación y preparación

Se usan tres folds expansivos de 13 semanas para ajustar hiperparámetros. La ventana de selección posterior (23 mar-15 jun 2012; 585 filas) elige la familia. La calibración de intervalos ocupa 22 jun-27 jul (270 filas); el test intacto, 03 ago-26 oct (585 filas). Imputación, escalamiento y bases spline se ajustan dentro de cada entrenamiento; no se barajan semanas. El modelo final se congela antes de abrir el test y no se reajusta durante este.

4. Modelos

Se contrastan baselines, regresión lineal y regularizada (Ridge, Lasso y Elastic Net), splines, árbol, Random Forest, boosting y promedio de modelos. Los hiperparámetros se eligen en folds temporales; el preprocesamiento se ajusta dentro de cada fold.

Comparación de validación (miles de unidades monetarias)

Modelo	Familia	RMSE k	MAE k	R^2	Reducción vs base
Random Forest	Ensamble	73.2	45.7	0.9822	27.6%
Promedio simple	Ensamble	75.6	47.0	0.9810	25.2%
Ridge	Regularizado	76.9	49.5	0.9803	23.9%
Elastic Net	Regularizado	78.5	49.1	0.9795	22.4%
Lasso	Regularizado	78.6	49.2	0.9794	22.3%
OLS	Lineal	80.0	51.6	0.9787	20.9%
Boosting	Ensamble	82.3	53.1	0.9774	18.6%
Semana t-52	Baseline anual	95.8	66.2	0.9695	5.3%
Spline	Flexible	96.0	75.7	0.9693	5.0%
Tree	Árbol	99.8	69.8	0.9668	1.3%
Semana previa	Baseline	101.1	64.1	0.9659	0.0%

Mejor en la ventana de selección: RandomForest, RMSE 73.2 mil. El promedio simple queda segundo (75.6 mil). El baseline semanal es la referencia; un porcentaje positivo indica reducción del RMSE.

Validación por formato de tienda: Random Forest frente al baseline semanal

Tipo	n	RMSE RF / base (mil)	Reducción RMSE
A	286	90.1 / 126.4	28.7%
B	221	59.3 / 76.8	22.8%
C	78	19.4 / 36.9	47.4%

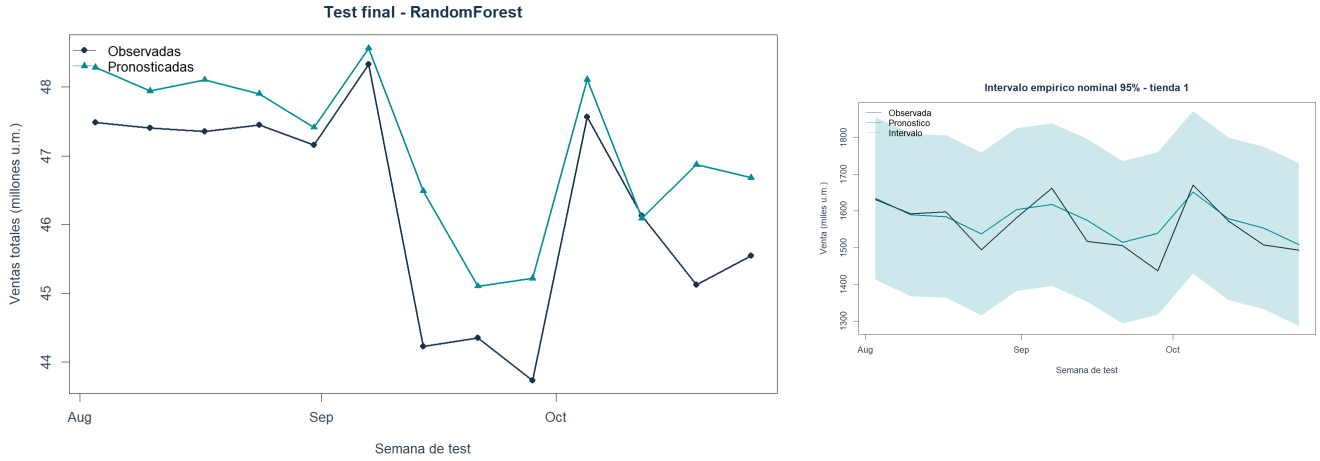
Configuración elegida: Random Forest, mtry=24, 300 árboles y nodesize=5. En las otras familias se seleccionaron Ridge lambda=0,01; Lasso lambda=0,003; Elastic Net lambda=0,003 y alpha=0,75; spline df=3; árbol cp=0,001; boosting profundidad=3 y shrinkage=0,08. El promedio es la media simple de Lasso, Random Forest y Boosting.

Semillas documentadas en el script: 2026 para ajustes, 20261109 para bootstrap y 341 para importancia por permutación.

Comparación, test y subgrupos

5. Comparación, test y subgrupos

Sistema	R^2	RMSE	MAE	Mejora vs semana previa
Random Forest	0.9880	57.9 mil	38.3 mil	22.3% RMSE; 22.2% MAE
Baseline semana previa	0.9800	74.5 mil	49.3 mil	Referencia



Ventas agregadas por semana de test (izq.) y bandas empíricas nominales del 95% para una tienda tipo A (der.).

Error por tipo y calibración de intervalos

Tipo	n	RMSE RF	RMSE base	Menor RMSE	MAE RF	Cobertura	Ancho medio
A	286	71.8	91.3	21.4%	49.9	97.9%	442.4
B	221	45.9	59.5	22.9%	32.2	95.9%	180.2
C	78	17.2	32.5	47.2%	13.1	96.2%	77.3

Cobertura global: 96.9% frente al 95% nominal; ancho medio 294.7 mil. Bandas por tipo calibradas en seis semanas separadas antes del test. El tipo C contiene seis tiendas (78 tienda-semanas), por lo que su estimación es menos estable. El sistema sobreestimó el total semanal en 12 de 13 semanas.

Sensibilidad bootstrap pareada por bloques móviles (5.000 remuestras)

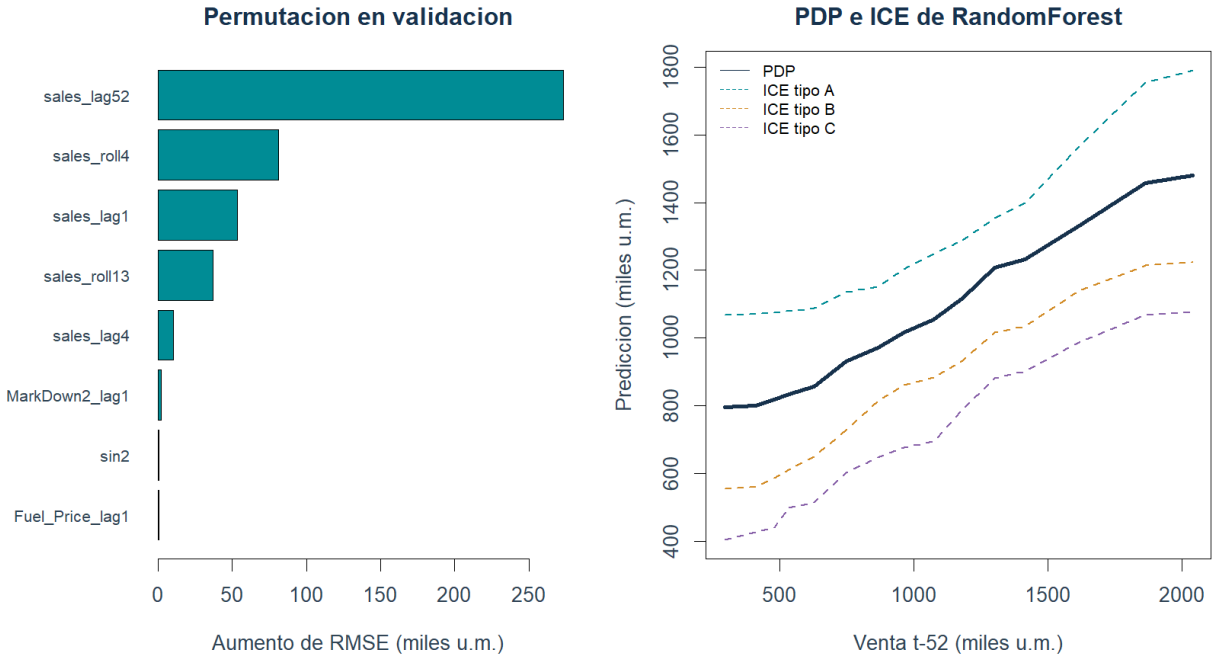
Bloque (semanas)	Mejora RMSE, IC 95%
2	[-4.4%; 35.8%]
3	[5.5%; 33.4%]
4	[6.7%; 31.7%]

Delta puntual = -16.6 mil; mejora puntual 22.3%. La sensibilidad al largo de bloque importa: el IC de dos semanas incluye cero; los de tres y cuatro semanas no.

Los intervalos porcentuales se obtienen con remuestreo móvil pareado de semanas; se muestran tres longitudes de bloque para hacer visible la sensibilidad de la comparación.

Interpretación, límites y recomendación

6. Interpretación, límites y recomendación



Importancia por permutación en validación (izq.) y PDP/ICE del Random Forest (der.).

La señal más fuerte es sales_lag52; le siguen sales_roll4, sales_lag1 y sales_roll13. En validación, permutar esas variables eleva el RMSE en 273.3 mil, 81.4 mil, 53.8 mil y 37.1 mil, respectivamente. El PDP promedio sube con las ventas de t-52 y los perfiles ICE mantienen niveles distintos por formato; son patrones del modelo, no efectos causales.

Recomendación: usar el modelo seleccionado como señal de planificación, con revisión humana. Monitorear error, sesgo y cobertura por semana y tipo; recalibrar y volver a validar con datos recientes antes de convertirlo en una regla operativa.

Límites

El historial termina en 2012; el test cubre solo 13 semanas; la unidad tienda-semana agrega departamentos; MarkDown tiene faltantes y los intervalos son amplios (ancho medio global 294,7 mil). No hay costos, margen ni inventario. El desempeño histórico no demuestra vigencia para tiendas o condiciones actuales.

7. Comparación y resultado final

La selección se realiza con la ventana temporal de validación y el sistema elegido se evalúa una sola vez en el test intacto; la comparación frente al baseline y su incertidumbre se reportan en las secciones 4 y 5.

Referencias

[1] Walmart Competition Admin y Will Cukierski (2014). *Walmart Recruiting - Store Sales Forecasting*. Kaggle. Dataset y metadatos de licencia: kaggle.com/c/walmart-recruiting-store-sales-forecasting/data. Licencia indicada: Subject to Competition Rules.

[2] Universidad de Santiago de Chile, Departamento de Ingeniería Industrial. Enunciado Caso 1: Regresión, Guía del informe (respaldo), plantilla y Pauta de evaluación, material del curso.

[3] R Core Team. *R: A Language and Environment for Statistical Computing*. La sesión incluida en el ZIP registra R 4.6.2.

[4] Documentación de CRAN para rpart, randomForest, gbm y glmnet; paquetes del script entregado.

A. Diccionario de variables

Disponibilidad y unidad de medida de los predictores principales. El paquete contiene el diccionario completo.

Grupo	Variables y disponibilidad
Respuesta	Weekly_Sales: suma de venta por tienda-semana; solo se conoce al cerrar t.
Calendario/tienda	time_idx, sin1/cos1, sin2/cos2, IsHoliday y dummies Store_2-Store_45; fecha, calendario e identidad conocidos al emitir.
Ventas históricas	sales_lag1, lag4, lag52 y promedios sales_roll4/roll13; usan observaciones anteriores a t.
Variables externas	Temperature_lag1, Fuel_Price_lag1, MarkDown1-5_lag1 y banderas missing; disponibilidad retrasada y faltantes imputados con mediana de entrenamiento.
No predictoras	Type solo define subgrupos. CPI y Unemployment se excluyen por disponibilidad temporal no acreditada; Dept solo agrega; Size queda absorbida por tienda.

B. Reproducibilidad y declaración de IA

Archivo / verificación	Descripción
codigo/walmart_analysis.2.1ma (1).R	Pipeline de selección temporal, calibración, test, inferencia y gráficos.
datos/train.csv, features.csv, stores.csv	Datos incluidos; el script admite archivos en subcarpetas con los mismos nombres.
resultados/*.csv, graficos/*.png, binarios/*.rds	Métricas, auditorías, interpretabilidad, intervalos y objetos congelados.
instrucciones_de_uso.txt	Entorno y pasos de ejecución incluidos en el paquete.
Verificación	Una sesión limpia de R 4.6.1 reprodujo las 27 tablas CSV del paquete; el entorno registrado originalmente usa R 4.6.2.

Se utilizó asistencia de IA para revisar redacción y formato; las cifras se contrastaron con los resultados CSV reproducidos.

El ZIP reúne código, datos, resultados, gráficos e información de ejecución para reproducir el análisis.