INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE

PROYECTO INTEGRADOR

REGRESIÓN

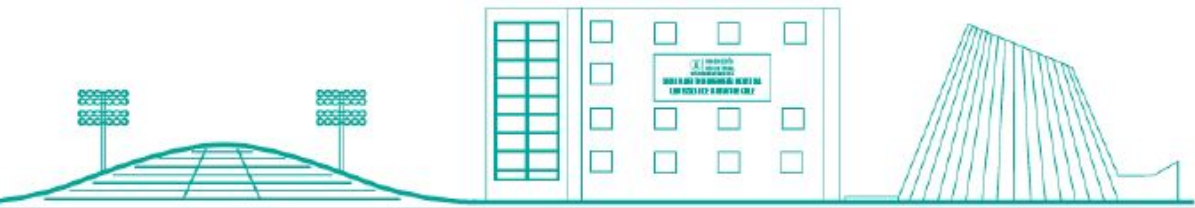
Pronóstico semanal de ventas

Caso Walmart · 45 tiendas

Integrantes:
Jeremías Martín Cisternas Campos
Andrés Ignacio Alan Pino Montecino
Matías Alejandro Jara Pérez
Pablo Eduardo Bustos Loyola
Gabriel Eduardo Moreira Hidalgo

Estadística Aplicada · Ingeniería Industrial · USACH

10 min de exposición | 10 min de preguntas



1. La predicción debe apoyar una decisión

El pronóstico estima ventas por tienda una semana adelante para apoyar planificación de demanda.

Problema y usuario

- Contexto: cadena minorista Walmart.
- Usuario: equipo de planificación de demanda.
- Unidad: tienda-semana (45 tiendas).
- Decisión: anticipar volumen semanal; no decide inventario automáticamente.
- Población: tiendas comparables con 52 semanas de historia.

Respuesta y consecuencias

- Respuesta continua: suma de Weekly_Sales por tienda.
- Corte: información conocida hasta t−1; horizonte: semana t.
- Sobreestimar puede generar planificación excesiva.
- Subestimar puede dejar demanda sin cobertura.
- No hay costos, márgenes ni stock para medir esas consecuencias.

Pregunta: ¿cuánto venderá cada tienda la próxima semana y con qué precisión?

2. El dataset se elige por su unidad y decisión

La fuente permite pasar de ventas por departamento a una serie semanal por tienda.

Fuente y cobertura

- Kaggle: Walmart Recruiting – Store Sales Forecasting.
- Licencia informada: “Subject to Competition Rules”.
- 05 feb 2010 – 26 oct 2012: 143 semanas.
- 421.570 filas; 45 tiendas y 81 departamentos.
- 6.435 tienda-semanas tras agregación.
- 4.095 observaciones modelables con rezago t−52.

Pertinencia y alcance

- Target: venta total semanal por tienda.
- Señales: calendario, tienda, historial de ventas y externas rezagadas.
- Alternativa de unidad: tienda-departamento de la competencia original.
- Aquí se agrupa por tienda y se evalúa RMSE, MAE y R^2, no WMAE.

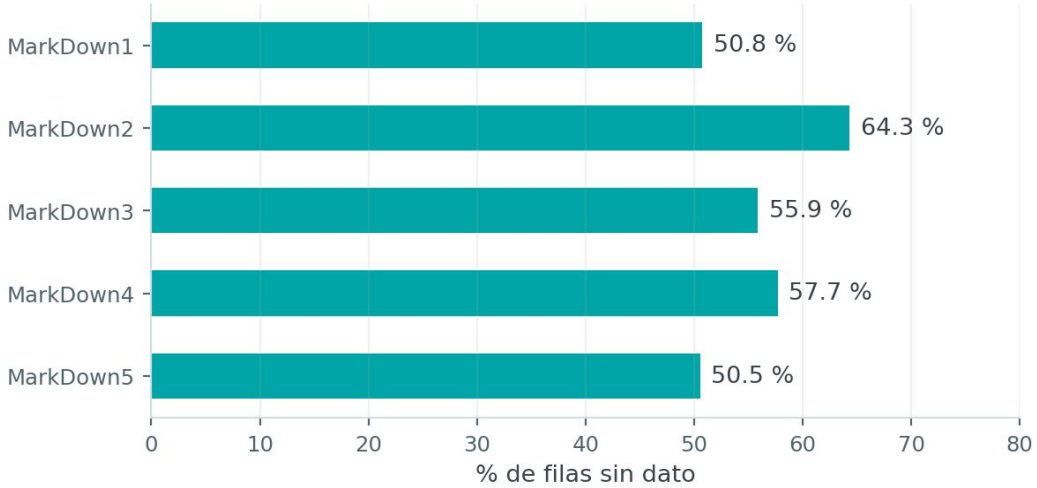
Se descartó el uso del data set “viral_songs” por falta de trazabilidad en la calidad de sus registros, el riesgo de leakage y la imposibilidad de definir un horizonte temporal óptimo.

3. El EDA cambia decisiones y la inferencia exige cautela

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Faltantes y asociaciones obligan a tratar datos sin fuga e interpretar las pendientes con cautela.

Calidad y preparación



1.285 ventas negativas y 73 ventas cero conservadas. Sin claves duplicadas. CPI y desempleo se excluyen por disponibilidad temporal no acreditada.

Relación estimada (OLS de referencia)

sales_lag52: β = 0,7675

IC 95 %: [0,6886; 0,8463] · p < 0,001

- 100.000 u.m. adicionales en t−52 se asocian con ≈76.746 u.m. más en t.
- VIF máximo = 214,7: multicolinealidad entre rezagos y promedios.
- Patrón predictivo, no efecto causal.

4. La evaluación debe simular el uso futuro

Tres folds expansivos, selección y calibración separadas; el test se abre una sola vez.

Partición cronológica

Historia	CV	Selección	Calibración	Test final
Hasta feb 2012	3 × 13 sem.	23 mar–15 jun	22 jun–27 jul	03 ago–26 oct

Controles sin fuga de información

- No se barajan semanas: cada bloque de validación sucede después del entrenamiento.
- Imputación, escalamiento y bases spline se ajustan dentro de cada fold de entrenamiento.
- Test: 13 semanas × 45 tiendas = 585 observaciones; no se usa para tuning ni para calibración.

5. Se compararon familias con capacidades distintas

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

La comparación incluye referencias simples, regresión lineal, regularización y modelos flexibles.

Familia, aporte y ajuste

Familia	Qué aporta	Ajuste principal
Baseline	Semana previa t−1 y estacional t−52	Sin tuning
OLS	Relación lineal y diagnóstico	Coeficientes
Ridge · Lasso · Elastic Net	Penalización y selección	λ y α
Spline natural	No linealidad suave	df
Árbol	Reglas por partición	cp
Random Forest	Ensamble de árboles	mtry · árboles · nodesize
Gradient Boosting	Árboles secuenciales	Profundidad · shrinkage
Promedio simple	Combina Lasso, RF y Boosting	Pesos iguales

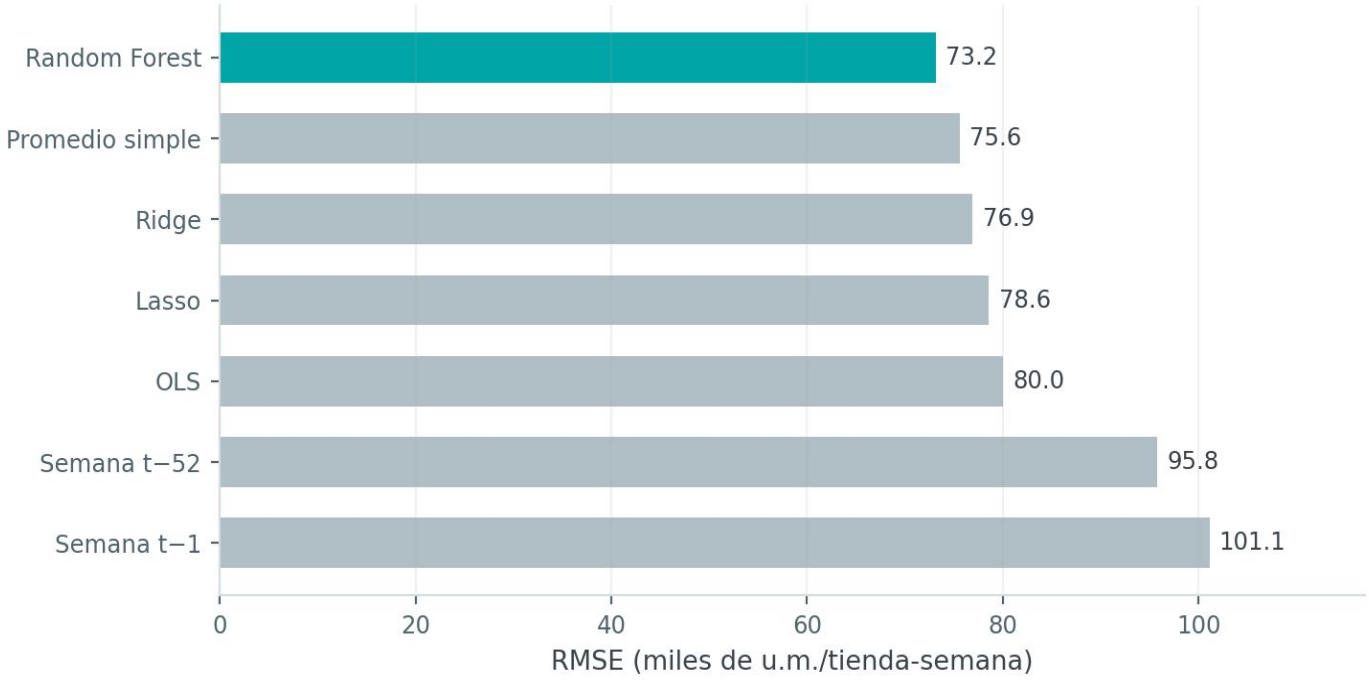
Seleccionado en validación: Random Forest · mtry = 24 · 300 árboles · nodesize = 5.

6. El baseline y la variabilidad importan

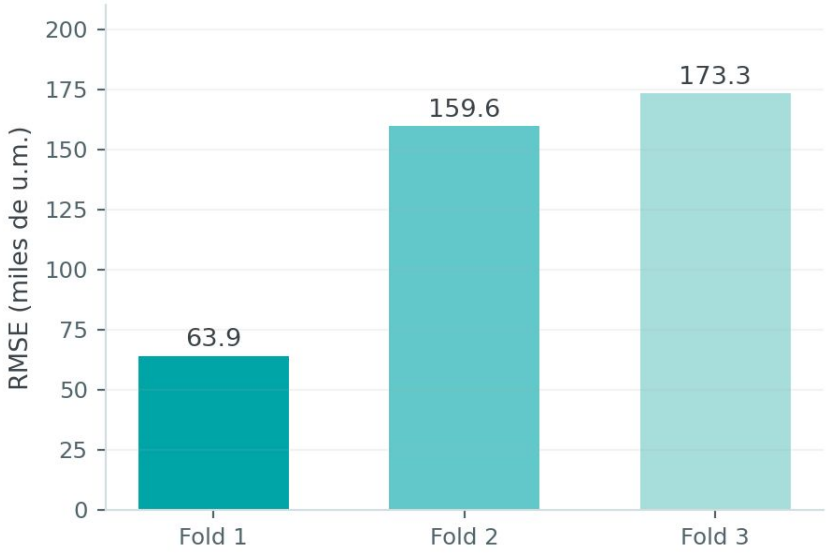
INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Random Forest logra el menor RMSE en selección, pero los folds muestran variación temporal.

RMSE en ventana de selección (menor es mejor)



Diferencias entre folds



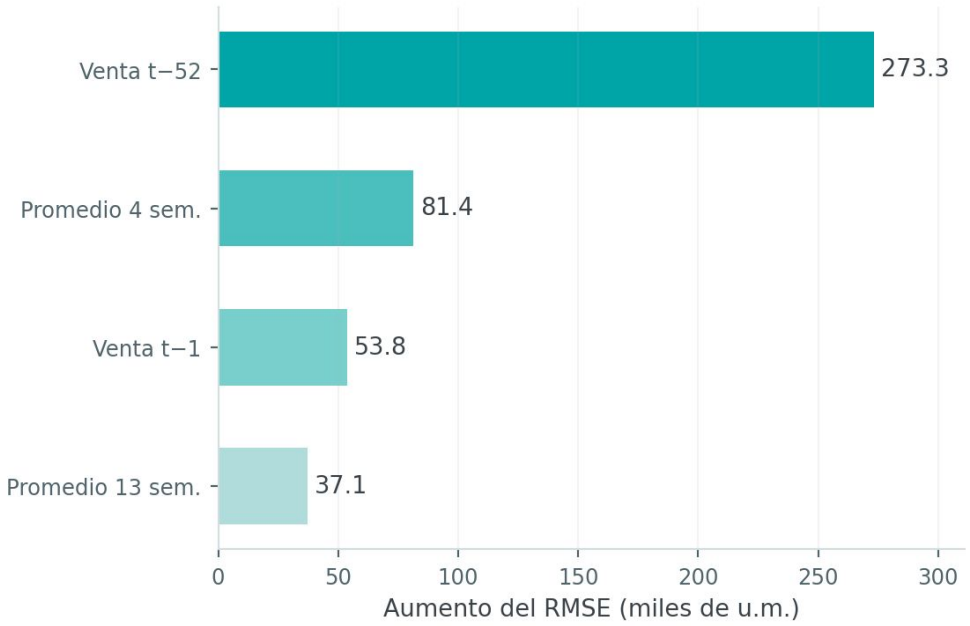
RF: 73,2 mil vs baseline 101,1 mil (−27,6 %).

7. Interpretar patrones predictivos, no causalidad

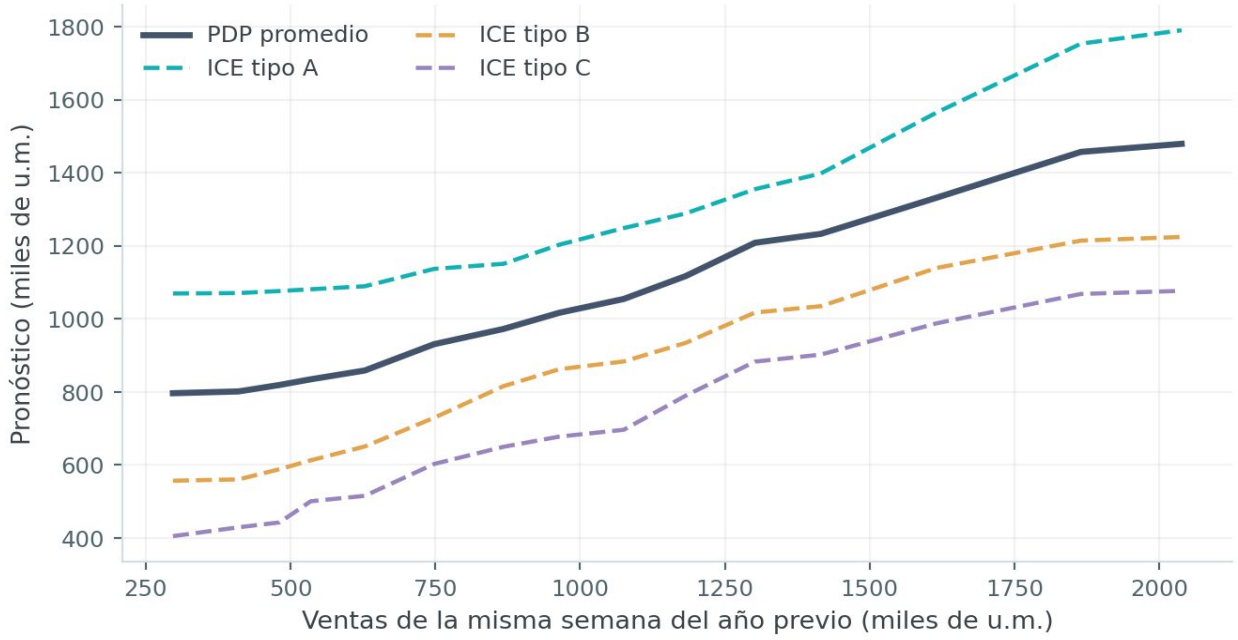
INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Las ventas del año anterior dominan la señal; los efectos parciales cambian según el tipo de tienda.

Importancia por permutación — RF



PDP e ICE — RF



Permutar sales_lag52 aumenta el RMSE ≈273,3 mil; esto no demuestra un efecto causal.

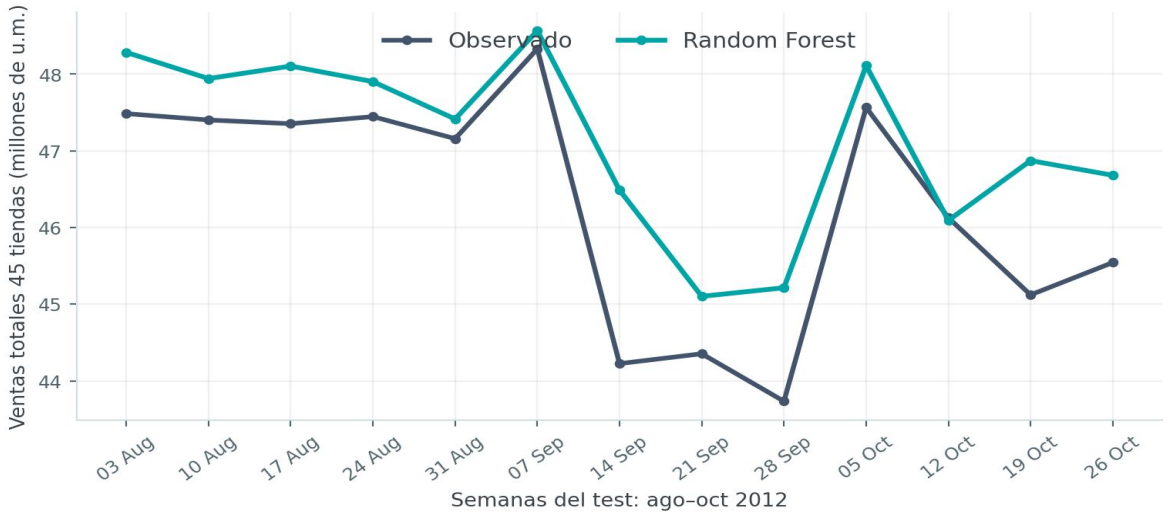
8. El test evalúa un sistema ya congelado

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

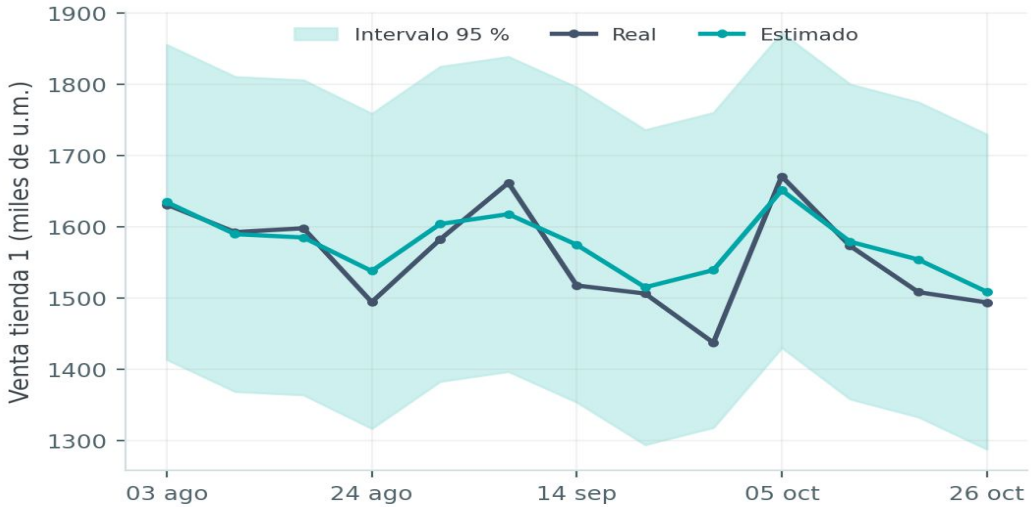
Random Forest mejora las cifras puntuales; los intervalos de predicción se calibraron antes del test.

RMSE	MAE	R^2	Mejora RMSE
57,9 mil	38,3 mil	0,9880	22,3 %

Ventas totales semanales: 45 tiendas



Intervalo 95 %: ejemplo tienda 1



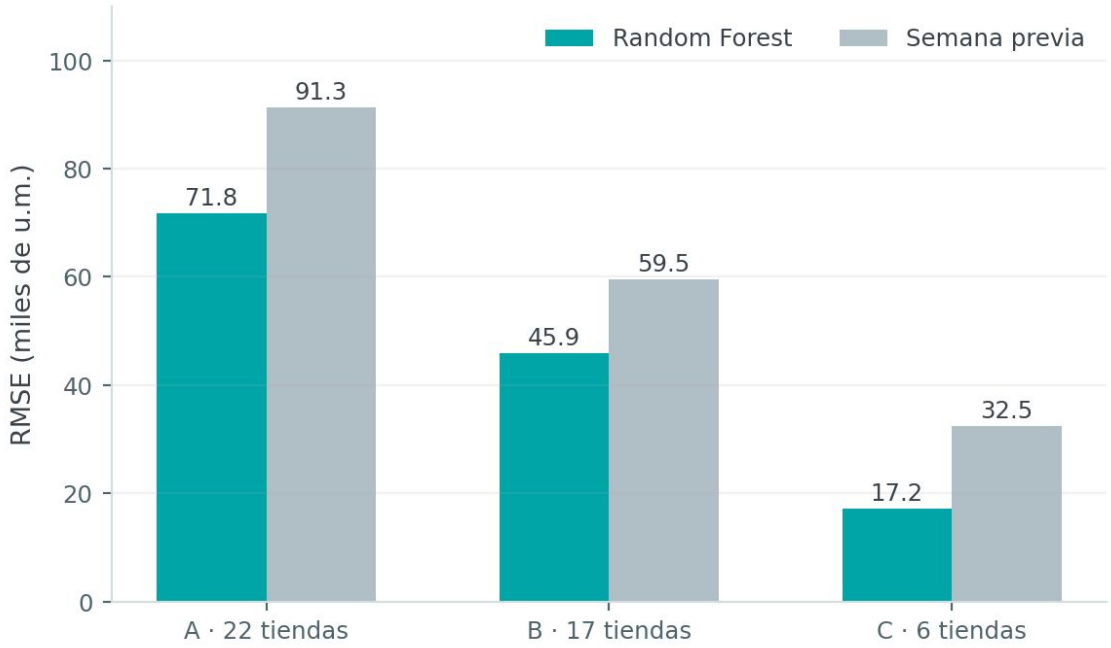
585 predicciones · baseline RMSE 74,5 mil · cobertura total 96,9 % (nominal 95 %).

9. El error cambia entre tiendas y semanas

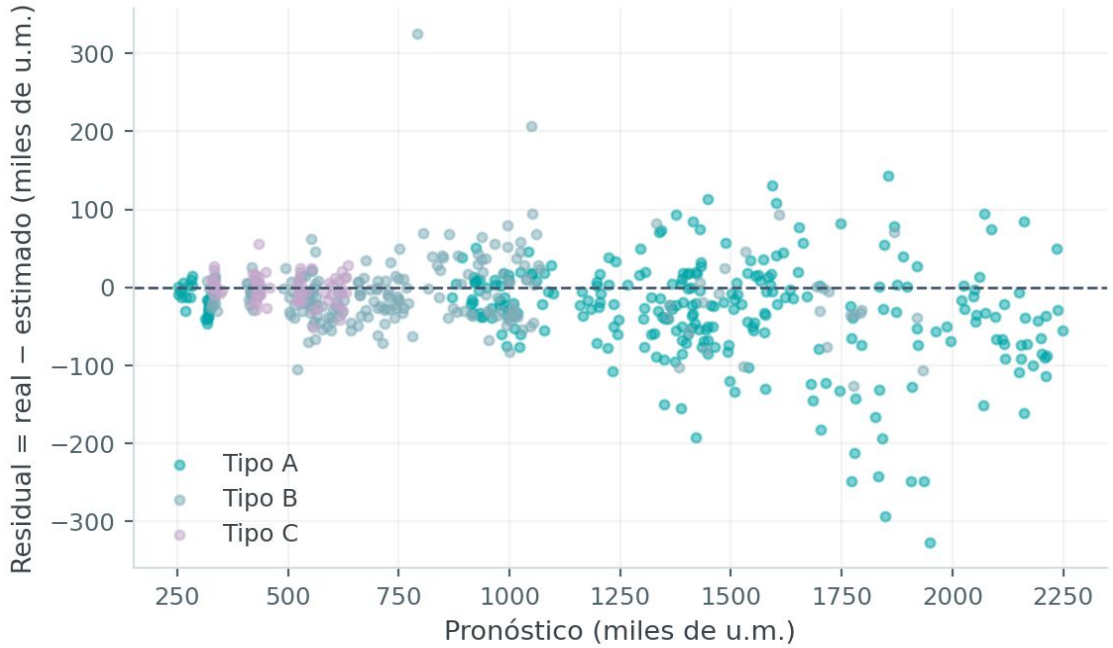
INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

El desempeño mejora por tipo de tienda, pero el sistema sobreestima el total en 12 de 13 semanas.

RMSE por formato de tienda



Residuos frente al pronóstico



A: 286 · B: 221 · C: 78 observaciones. El tipo C (6 tiendas) es menos estable.

10. Recomendación con límites y monitoreo

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

La evidencia apoya un piloto supervisado, no automatizar decisiones con datos históricos de 2012.

Recomendación

- Usar Random Forest como señal semanal de planificación, con revisión humana.
- Comparar siempre con el baseline de la semana previa.
- Revalidar y recalibrar con datos actuales antes de un despliegue.
- No proyecta ganancias ni optimiza inventario: faltan costos, márgenes y stock.

Monitoreo recomendado

Indicador	Seguimiento
RMSE y MAE	Semanal, vs baseline
Sesgo semanal	Por tienda y total
Cobertura intervalos	Semanal y por tipo
Drift y faltantes	Al actualizar datos
Deterioro persistente	Revalidar/reentrenar

Límites: historia 2010–2012 · 13 semanas de test · desempeño incierto según longitud de bloque del bootstrap.

PREGUNTAS Y DEFENSA TÉCNICA

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

10 minutos · Todos deben defender datos, validación, modelos y decisiones.